Департамент образования и науки города Москвы Государственное автономное образовательное учреждение высшего образования города Москвы

«Московский городской педагогический университет» Институт цифрового образования

Департамент информатики, управления и технологий

ДИСЦИПЛИНА:

«Проектный практикум по разработке ETL-решений»

Практическая работа № 6 Тема:

«Оркестровка конвейера данных».

Выполнила: Нестратова А.М., АДЭУ-201

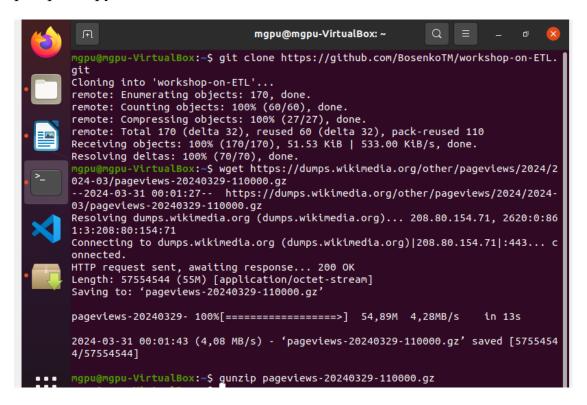
Преподаватель: Босенко Т.М.

Москва

Разворачиваем ВМ ubuntu_mgpu.ova в VirtualBox.



Клонируем на ПК задание Бизнес-кейс «StockSense» в домашний каталог ВМ. Скачиваем данные наиболее часто используемых кодах доменов, разархивируем.



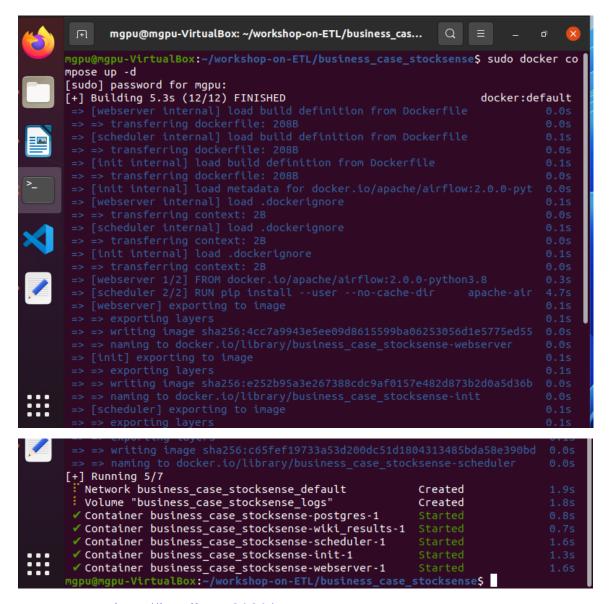
Выводим первые строки данных за 29 марта 2024 года 11:00.

```
mgpu@mgpu-VirtualBox: ~
                                                         Q
--2024-03-31 00:01:27-- https://dumps.wikimedia.org/other/pageviews/2024/2024-
03/pageviews-20240329-110000.gz
Resolving dumps.wikimedia.org (dumps.wikimedia.org)... 208.80.154.71, 2620:0:86
1:3:208:80:154:71
Connecting to dumps.wikimedia.org (dumps.wikimedia.org)|208.80.154.71|:443... c
onnected.
HTTP request sent, awaiting response... 200 OK
Length: 57554544 (55M) [application/octet-stream]
Saving to: 'pageviews-20240329-110000.gz'
in 13s
2024-03-31 00:01:43 (4,08 MB/s) - 'pageviews-20240329-110000.gz' saved [5755454
4/57554544]
mgpu@mgpu-VirtualBox:~$ gunzip pageviews-20240329-110000.gz
                                  '{print $1}' pageviews-20240329-110000 | sor
mgpu@mgpu-VirtualBox:~$ awk -F
t | uniq -c | sort -nr | head
1125763 en.m
837733 en
288548 de.m
268755 ru.m
 257505 ja.m
215087 de
 209257 ru
208388 fr
194089 fr.m
 167990 es.m
mgpu@mgpu-VirtualBox:~$
```

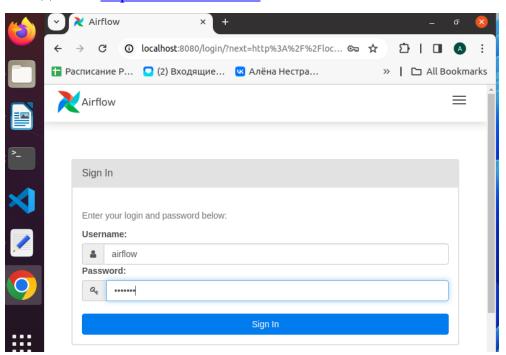
Меняем файл listing_4_20.py в папке dags.

```
*listing_4_20.py
  Open
                Ħ
                                                                Save
                        ~/workshop-on-ETL/busine
45
       task_id="extract_gz", bash_command="gunzip --force /tmp/-
  wikipageviews.gz", dag=dag
46)
47
48
49 def _fetch_pageviews(pagenames, execution_date):
       result = dict.fromkeys(pagenames, 0)
50
51
       with open("/tmp/wikipageviews",
                                            "r") as f:
52
            for line in f:
                domain_code, page_title, view_counts, _ = line.split(" ")
if domain_code == "ru" and page_title in pagenames:
    result[page_title] = view_counts
53
54
55
56
57
       with open("/tmp/postgres_query.sql", "w") as f:
58
            for pagename, pageviewcount in result.items():
59
                 f.write(
60
                     "INSERT INTO pageview_counts VALUES ("
                     f"'{pagename}', {pageviewcount}, '{execution_date}'"
61
                     ");\n"
62
63
                 )
64
65
66 fetch_pageviews = PythonOperator(
       task_id="fetch_pageviews",
67
68
       python_callable=_fetch_pageviews,
       op_kwargs={"pagenames": {"Telegram", "Ozon", "Avito", "Wildberries",
69
  "Yandex"}},
70
       dag=dag
                                      Python ▼ Tab Width: 8 ▼ Ln 69, Col 81 ▼
```

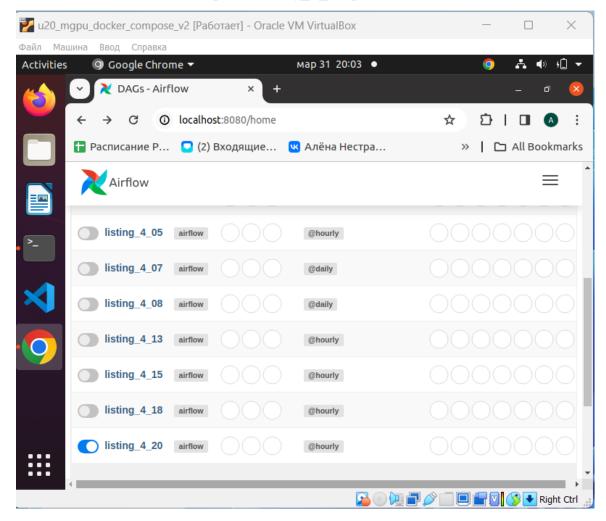
Запускаем контейнер.



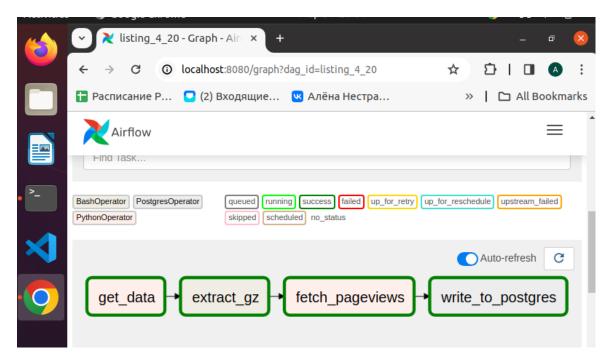
Заходим на http://localhost:8080/



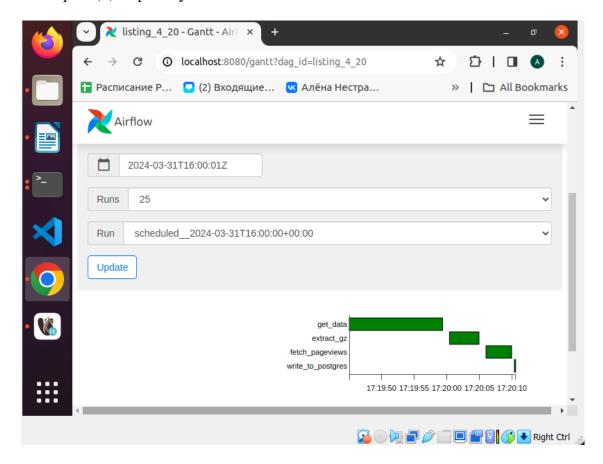
Запускаем только файл listing_4_20.py



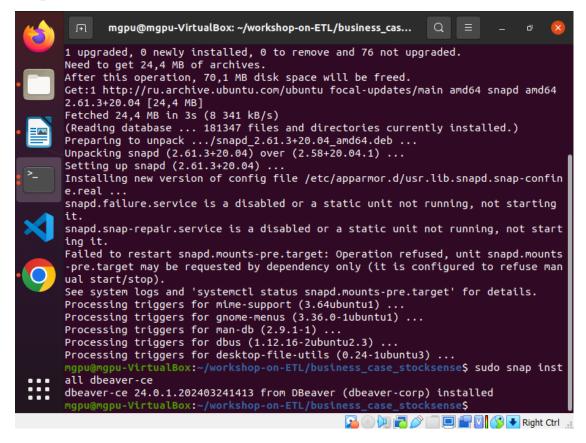
Проверяем, что все стадии отработали



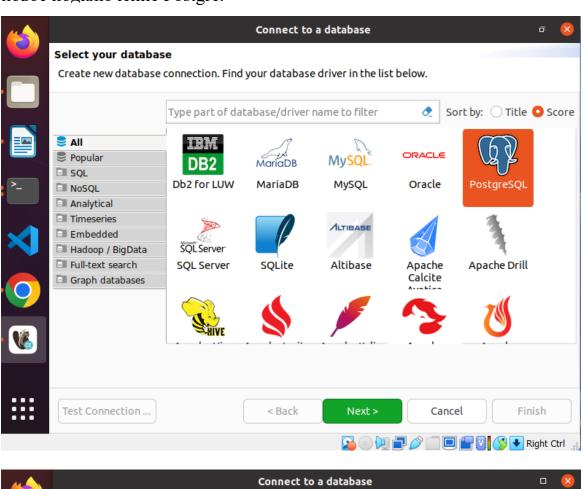
Смотрим Диаграмму Ганта

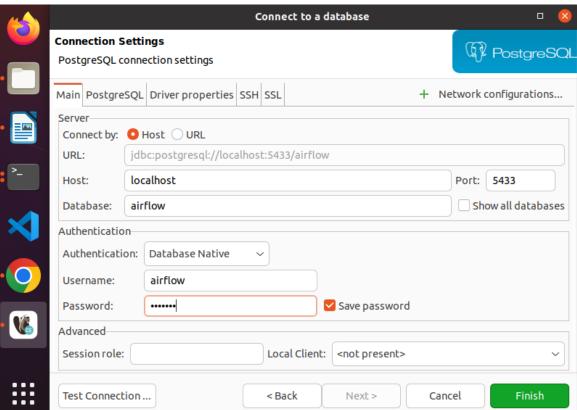


Устанавливаем DBeaver. Через него подключимся к бд и напишем sql запрос к данным.

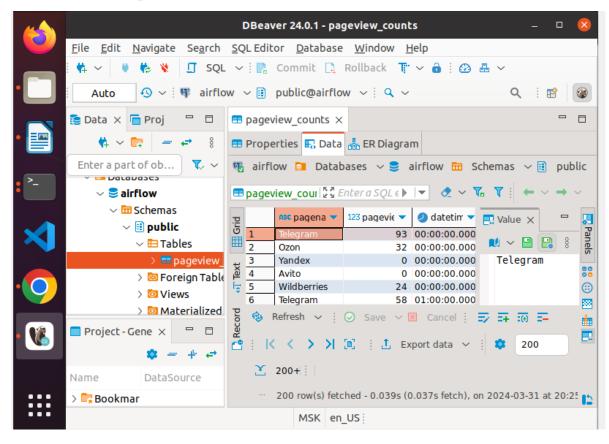


Оно появляется в каталоге приложений. Открываем его. Добавляем новое подключение Postgre.

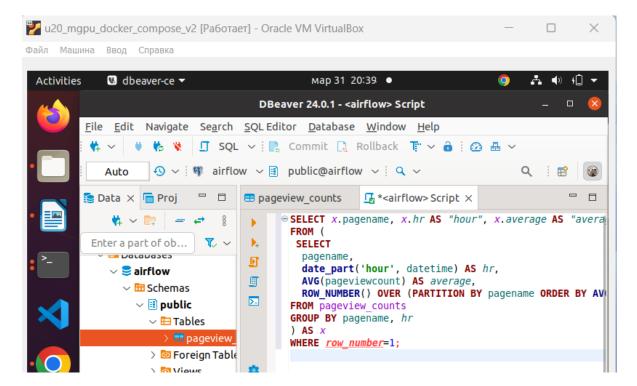




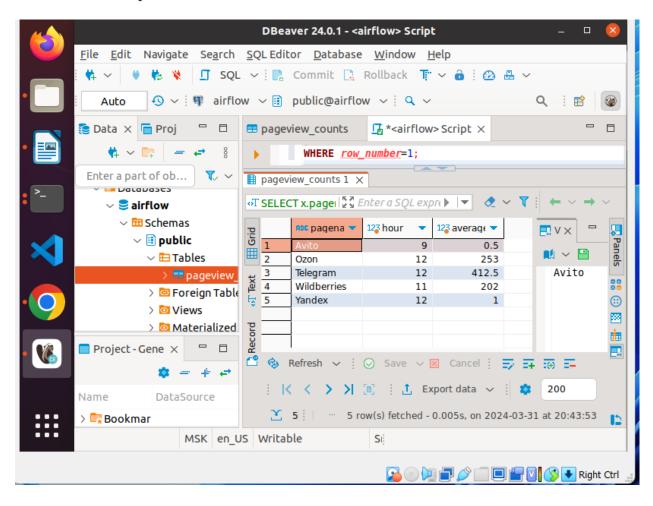
Разворачиваем таблицу с данными о посещениях страниц компаний, добавленных в файле.



Пишем запрос в терминале



Выполняем запрос



- 6.1.5. Спроектировать верхнеуровневую архитектуру аналитического решения задания Бизнес-кейса «StockSense» в draw.io. Необходимо использовать:
 - Source Layer слой источников данных.
 - Storage Layer слой хранения данных.
 - Business Layer слой для доступа к данным пользователей.
- 6.1.6. Спроектировать архитектуру DAG Бизнес-кейса «StockSense» в draw.io. Необходимо использовать:
 - Source Layer слой источников данных.
 - Storage Layer слой хранения данных.
 - Business Layer слой для доступа к данным пользователей.